

1단계 : 데이터 이해 및 준비 (책임 : 허여령, 이세은)

(2)결측치 및 이상치 탐색 : 누락값/이상치 존재 여부 확인 및 처리 방안 수립

ㄱ. 결측치 (누락값)

-모든 컬럼에 결측치 없음.

=> 데이터는 완전하며, 따로 결측값 처리를 하지 않아도 된다.

ㄴ. 이상치 (Outlier, 데이터 전체의 일반적인 패턴에서 크게 벗어난 값)

*IQR 기반 탐지

*IQR(사분위 범위) = $Q3 - Q1$ (상위 75%지점 - 하위 25%지점)

*이상치 하한 : $Q1 - 1.5 * IQR$ || 이상치 상한 : $Q3 + 1.5 * IQR$

[이상치 계산 코드]

```
import pandas as pd

# CSV 파일 불러오기
df = pd.read_csv("C:/osp_pakin/train_activity.csv.part0") # 파일 경로는
# 필요에 따라 조정

# 분석할 열 지정
column = 'activity_score' # 여기에 원하는 컬럼명을 바꾸면 됨
#column = 'activity_steps'
#column = 'activity_inactive'
#column = 'activity_non_wear'
#column = 'activity_score_meet_daily_targets'
#column = 'activity_score_move_every_hour'

# 결측치 제거 (필수)
data = df[column].dropna()

# Q1, Q3, IQR 계산
q1 = data.quantile(0.25)
q3 = data.quantile(0.75)
iqr = q3 - q1

# 이상치 기준 계산
lower_bound = q1 - 1.5 * iqr
upper_bound = q3 + 1.5 * iqr

# 이상치 탐지
outliers = data[(data < lower_bound) | (data > upper_bound)]

# 이상치 행 출력
```

```

outlier_rows = df[(df[column] < lower_bound) | (df[column] >
upper_bound)]
print(outlier_rows)

# 결과 출력
print(f"[{column}] 열의 전체 값 개수 (결측치 제외): {len(data)}")
print(f"[{column}] 열 이상치 개수: {len(outliers)}")
print(f"이상치 하한: {lower_bound:.2f}, 상한: {upper_bound:.2f}")
print("이상치 예시 상위 5개:")
print(outliers.head())
print("모든 이상치:")
print(outliers)

```

[activity_score : 활동점수 (0~100)]

[41 rows x 31 columns]

[activity_score] 열의 전체 값 개수 (결측치 제외): 9705

[activity_score] 열 이상치 개수: 41

이상치 하한: 44.00, 상한: 124.00

이상치 예시 상위 5개:

```

4320  42
4373  43
5308  42
5309  43
5315  40

```

Name: activity_score, dtype: int64

모든 이상치:

```

4320  42
4373  43
5308  42
5309  43
5315  40
5323  32
5324  38
5325  41
5326  35
5327  42
5328  42
5337  39
5338  31
5339  38
5340  33
5341  33
5342  31
5343  43
5344  33
5353  39

```

```
5531 34
5532 41
6537 43
6553 42
6554 40
6561 41
6562 42
6566 42
6567 38
6569 39
6903 42
6918 42
7728 0
7729 0
7730 0
7731 0
7732 0
7733 0
7734 0
7735 0
7736 0
```

Name: activity_score, dtype: int64

[activity_steps : 걸음 수]

[160 rows x 31 columns]

[activity_steps] 열의 전체 값 개수 (결측치 제외): 9705

[activity_steps] 열 이상치 개수: 160

이상치 하한: -5663.00, 상한: 26249.00

이상치 예시 상위 5개:

```
458 28067
476 28585
1237 26836
1239 27471
1245 27633
```

Name: activity_steps, dtype: int64

모든 이상치:

```
458 28067
476 28585
1237 26836
1239 27471
1245 27633
```

...

```
9652 29684
9667 33289
9668 30090
9669 41193
9673 28797
```

Name: activity_steps, Length: 160, dtype: int64

****이상치 하한 값이 음수(-5663.00)값이 나온 이유**

: **Q1(25%)과 Q2(75%) 지점의 간격이 좁으면**, IQR도 작고, Lower_bound 가 음수가 될 수 있음

: 현실적으로, 걸음 수(activity_steps)는 0이상이어야 함

(결론) 음수 하한 값은 단순 수학적 기준일 뿐, 실제 데이터 의미와 맞지 않음

****실제 해석 : 실제 outliers 시리즈를 보면 전부 양수 + 매우 높은 걸음 수이다.**

이상치로 판정된 값들은 모두 상한(26249) 초과 값들이다.

[activity_inactive : 활동 강도별 시간(분 단위), 활동하지 않음]

[121 rows x 31 columns]

[activity_inactive] 열의 전체 값 개수 (결측치 제외): 9705

[activity_inactive] 열 이상치 개수: 121

이상치 하한: 141.50, 상한: 873.50

이상치 예시 상위 5개:

120 19

136 69

351 94

504 60

1066 881

Name: activity_inactive, dtype: int64

모든 이상치:

120 19

136 69

351 94

504 60

1066 881

...

9598 60

9636 71

9641 896

9669 89

9704 69

Name: activity_inactive, Length: 121, dtype: int64

[activity_non_wear : 장치 미착용 시간]

[422 rows x 31 columns]

[activity_non_wear] 열의 전체 값 개수 (결측치 제외): 9705

[activity_non_wear] 열 이상치 개수: 422

이상치 하한: -114.00, 상한: 190.00

이상치 예시 상위 5개:

123 298

125 199

136 284

174 289

185 263

Name: activity_non_wear, dtype: int64

모든 이상치:

123 298

```
125    199
136    284
174    289
185    263
```

```
...
9565   194
9569   223
9634   220
9656   194
9690   239
```

Name: activity_non_wear, Length: 422, dtype: int64

****[activity_stpes]와 동일한 이유로 이상치 하한 값이 음수(-114.00)**

****실제 해석 : 실제 outliers 시리즈는 전부 이상치 상한 값을 초과한 값**

[activity_score_meet_daily_targets : 일일 목표 달성 점수]

Index: []

[activity_score_meet_daily_targets] 열의 전체 값 개수 (결측치 제외): 9705

[activity_score_meet_daily_targets] 열 이상치 개수: 0

이상치 하한: 0.00, 상한: 160.00

이상치 예시 상위 5개:

Series([], Name: activity_score_meet_daily_targets, dtype: int64)

모든 이상치:

Series([], Name: activity_score_meet_daily_targets, dtype: int64)


****이상치가 없는 상태** : 극단적으로 크거나 작은 값이 존재하지 않는, 꽤 일정한 분포를 가진 데이터

****정규화된 점수, 제한 범위가 있는 값에서는 혼함. 데이터 품질이 양호하다는 뜻**

****추가 확인을 위한 히스토그램 만드는 코드**

```
import matplotlib.pyplot as plt

df['activity_score_meet_daily_targets'].hist(bins=30)
plt.title('Distribution of activity_score_meet_daily_targets')
plt.xlabel('Score')
plt.ylabel('Frequency')
plt.grid(True)
plt.show()
```



[activity_score_move_every_hour : 매 시각 움직이기 점수]

[863 rows x 31 columns]

[activity_score_move_every_hour] 열의 전체 값 개수 (결측치 제외): 9705

[activity_score_move_every_hour] 열 이상치 개수: 863

이상치 하한: 87.50, 상한: 107.50

이상치 예시 상위 5개:

19 78

28 78

75 60

84 78

98 78

Name: activity_score_move_every_hour, dtype: int64

모든 이상치:

19 78

28 78

75 60

84 78

98 78

..

9695 60

9696 60

9697 60

9699 78

9700 43

Name: activity_score_move_every_hour, Length: 863, dtype: int64